



**Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

**Факультет «Информатика, искусственный и системы управления»
Кафедра «Системы обработки информации и управления»**

**Отчет по Лабораторной работе №6
*«Анализ и прогнозирование
временного ряда»*
по дисциплине «Технология машинного обучения»**

**Выполнил:
студент группы ИУ5-61Б
И.А. Абуховский**

**Проверил:
Ю.Е. Гапанюк**

2023 г.

```
In [7]: import numpy as np
import pandas as pd
from matplotlib import pyplot
import matplotlib.pyplot as plt
```

```
In [8]: df = pd.read_csv('births.csv', index_col = "Date", parse_dates = True)
```

```
In [9]: df.head()
```

```
Out[9]:
```


Births	
Date	
1959-01-01	35
1959-01-02	32
1959-01-03	30
1959-01-04	31
1959-01-05	44

```
In [10]: df.shape
```

```
Out[10]: (365, 1)
```


```
In [11]: fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Плотность вероятности распределения данных')
df.plot(ax=ax, kind='kde', legend=False)
pyplot.show()
```

Плотность вероятности распределения данных




```
In [12]: for i in range(1, 5):
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(5,4))
fig.suptitle(f'Лег порядка {i}')
pd.plotting.lag_plot(df, lag=i, ax=ax)
pyplot.show()
```


Лег порядка 1




Лег порядка 2



Лег порядка 3




Лег порядка 4




```
In [13]: fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Автокорреляционная диаграмма')
pd.plotting.autocorrelation_plot(df, ax=ax)
pyplot.show()
```

Автокорреляционная диаграмма



```
In [14]: from statsmodels.graphics.tsaplots import plot_acf
plot_acf(df, lags=30)
plt.tight_layout()
```




```
In [15]: df.index = pd.to_datetime(df.index)
```

```
In [16]: # импортируем функцию seasonal_decompose из statsmodels
from statsmodels.tsa.seasonal import seasonal_decompose

# задаем размер графика
from pylab import rcParams
rcParams['figure.figsize'] = 11, 9

# применяем функцию к данным
decompose = seasonal_decompose(df)
decompose.plot()

plt.show()
```




```
In [17]: # зададим размер графика
plt.figure(figsize = (15,8))

# поочередно зададим кривые (перевозки и скользящее среднее) с подписями и цветом
plt.plot(df, label = 'Рожденные люди', color = 'steelblue')
plt.plot(df.rolling(window = 30).mean(), label = 'Скользящее среднее', color = 'orange')

# добавим легенду, ее положение на графике и размер шрифта
plt.legend(title = '', loc = 'upper left', fontsize = 14)

# добавим подписи к осям и заголовки
plt.xlabel('Дата', fontsize = 14)
plt.ylabel('Количество людей', fontsize = 14)
plt.title('Рожденные люди', fontsize = 16)

# выведем обе кривые на одном графике
plt.show()
```



```
In [18]: # импортируем необходимую функцию
from statsmodels.tsa.stattools import adfuller

# передадим ей столбец с данными о перевозках и поместим результат в adf_test
adf_test = adfuller(df['Births'])

# выведем p-value
print('p-value = ' + str(adf_test[1]))

p-value = 5.243412990149949e-05
```

```
In [19]: from statsmodels.tsa.holtwinters import ExponentialSmoothing
from sklearn.metrics import mean_squared_error
from statsmodels.tsa.arima.model import ARIMA
```

```
In [20]: xnum = list(range(df.shape[0]))
Y = df['Births'].values
train_size = int(len(Y) * 0.7)
xnum_train, xnum_test = xnum[0:train_size], xnum[train_size:]
train, test = Y[0:train_size], Y[train_size:]
```

```
In [21]: history_arima = [x for x in train]
history_es = [x for x in train]
```

```
In [22]: arima_order = (6,1,0)
```

```
In [23]: predictions_arima = list()
for t in range(len(test)):
    model_arima = ARIMA(history_arima, order=arima_order)
    model_arima_fit = model_arima.fit()
    yhat_arima = model_arima_fit.forecast()[0]
    predictions_arima.append(yhat_arima)
    history_arima.append(test[t])
```

```
In [24]: error_arima = mean_squared_error(test, predictions_arima, squared=False)
```

```
In [25]: predictions_es = list()
for t in range(len(test)):
    model_es = ExponentialSmoothing(history_es)
    model_es_fit = model_es.fit()
    yhat_es = model_es_fit.forecast()[0]
    predictions_es.append(yhat_es)
    history_es.append(test[t])
```

```
In [26]: error_es = mean_squared_error(test, predictions_es, squared=False)
```

```
In [29]: print("MSE ARIMA: ", error_arima)
print("MSE HWES: ", error_es)
```

```
MSE ARIMA: 7.082306329654917
MSE HWES: 7.217016868586756
```

```
In [37]: df['predictions_ARIMA'] = (train_size * [np.NaN]) + list(predictions_arima)
```




```
df['predictions_HWES'] = (train_size * [np.NaN]) + list(predictions_es)
```

```
In [40]: df['SMA'] = df['Births'].rolling(30, min_periods=1).mean()
```


```
In [41]: fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Предсказания временного ряда')
df.plot(ax=ax, legend=True)
pyplot.show()
```

Предсказания временного ряда



```
In [42]: fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Предсказания временного ряда (тестовая выборка)')
df[train_size:].plot(ax=ax, legend=True)
pyplot.show()
```

Предсказания временного ряда (тестовая выборка)



ARIMA и HWES близки к скользящему среднему

```
In [45]: from gplearn.genetic import SymbolicRegressor
```

```
%pip install gplearn
```

```
In [46]: function set = ['add', 'sub', 'mul', 'div', 'sin']
```



```
est_gp = SymbolicRegressor(population_size=500, metric='mse',
                           generations=70, stopping_criteria=0.01,
                           init_depth=(4, 10), verbose=1, function_set=function_set,
                           const_range=(-100, 100), random_state=0)
```

```
In [47]: est_gp.fit(np.array(xnum_train).reshape(-1, 1), train.reshape(-1, 1))
```

C:\anaconda3\lib\site-packages\sklearn\utils\validation.py:993: DataConversionWarning: A column-vector y was passed when a 1d array was expected. Please change the shape of y to (n_samples,), for example using ravel().

```
y = column_or_1d(y, warn=True)
```

Population Average			Best Individual			
Gen	Length	Fitness	Length	Fitness	00B Fitness	Time Left
0	263.65	7.25395e+55	26	368.24	N/A	1.93m
1	168.80	3.08763e+11	190	137.664	N/A	57.31s
2	187.17	1.23463e+10	190	137.64	N/A	54.87s
3	126.69	3.36087e+22	14	63.3652	N/A	42.64s
4	178.60	6.78824e+13	14	63.3685	N/A	53.37s
5	123.38	1.01443e+14	10	58.1649	N/A	41.21s
6	16.83	3.043e+14	25	57.1643	N/A	18.65s
7	13.11	4.06308e+14	9	50.0916	N/A	19.34s
8	15.99	4.05734e+14	22	50.0506	N/A	18.61s
9	15.88	4.87469e+15	10	49.9905	N/A	20.16s
10	15.11	2.53812e+15	41	49.8642	N/A	19.47s
11	23.48	1.18829e+16	61	49.5823	N/A	19.32s
12	26.29	2.84417e+15	19	49.2251	N/A	21.55s
13	41.60	2.85776e+15	18	48.5365	N/A	22.46s
14	52.15	7.12366e+15	29	48.4612	N/A	24.42s
15	44.79	1.81606e+11	137	48.1081	N/A	22.79s
16	38.99	37707.7	150	48.0293	N/A	21.36s
17	57.33	5.89249e+06	59	47.2986	N/A	24.49s
18	101.51	3.40558e+06	40	47.1072	N/A	34.02s
19	97.39	1.701e+06	64	46.9361	N/A	28.80s
20	67.71	30533.4	150	46.8244	N/A	24.79s
21	73.77	59189.6	79	46.2824	N/A	25.28s
22	85.94	37425.4	113	46.2358	N/A	26.47s
23	97.07	1.30434e+06	61	45.8434	N/A	28.83s
24	96.01	1.79859e+06	142	45.1803	N/A	26.86s
25	108.38	686066	142	45.1803	N/A	28.56s
26	130.18	1.06313e+06	154	44.8865	N/A	30.53s
27	151.34	362193	152	44.7084	N/A	32.17s
28	173.31	12847.7	256	44.563	N/A	37.23s
29	170.85	708637	131	43.4877	N/A	34.96s
30	164.65	18007.3	131	43.4877	N/A	32.21s
31	159.97	7.12214e+06	204	43.0844	N/A	39.60s
32	152.48	912883	204	43.0844	N/A	30.01s
33	157.81	841393	296	42.874	N/A	32.40s
34	202.25	2.11938e+06	321	42.627	N/A	33.46s
35	247.06	951483	518	42.5981	N/A	36.35s
36	252.69	22821.2	421	42.2247	N/A	36.23s
37	276.74	245656	420	42.1337	N/A	39.97s
38	347.55	11894.9	294	41.951	N/A	45.67s
39	390.84	1.3304e+06	720	41.7752	N/A	48.72s
40	410.14	254.802	762	41.7562	N/A	48.69s
41	331.65	6379.31	466	41.0082	N/A	38.65s
42	298.96	828984	552	40.4083	N/A	36.15s
43	368.48	818223	551	39.8089	N/A	41.11s
44	461.59	348617	692	39.3182	N/A	45.53s
45	575.49	23406.9	626	39.2141	N/A	53.69s
46	603.84	74068.7	693	38.3947	N/A	53.13s
47	678.43	17712.6	716	38.1826	N/A	54.47s
48	684.47	1933.23	755	37.9086	N/A	51.28s
49	699.80	535678	755	37.7096	N/A	51.12s
50	716.31	34874.9	741	37.7048	N/A	54.51s
51	748.82	18785.5	808	37.4716	N/A	48.94s
52	759.12	5933.17	1274	37.3378	N/A	47.11s
53	747.69	34420.9	1193	36.9635	N/A	41.78s
54	788.61	229922	1216	35.4431	N/A	40.50s
55	845.38	11874.9	1236	35.4172	N/A	41.69s
56	1159.01	11922.7	1216	34.917	N/A	52.82s
57	1224.57	28908.2	1271	34.5268	N/A	51.30s
58	1236.54	529802	1270	34.416	N/A	49.79s
59	1233.49	214.684	1160	34.3678	N/A	41.83s
60	1234.42	287984	1249	34.2335	N/A	39.51s
61	1228.73	5863.85	1343	33.9161	N/A	35.58s
62	1236.84	17811.7	1363	33.9147	N/A	31.66s
63	1261.26	23379.8	1346	33.748	N/A	27.21s
64	1277.07	16949.9	1346	33.2909	N/A	24.65s
65	1274.63	17486.8	1335	33.2896	N/A	18.72s
66	1289.95	119.186	1371	33.1259	N/A	13.63s
67	1319.21	17531.2	2614	32.9963	N/A	9.42s
68	1322.92	222.319	1437	33.0886	N/A	4.86s
69	1329.79	295.903	1271	32.8986	N/A	0.00s

```
Out[47]: SymbolicRegressor(const_range=(-100, 100),
                           function_set=['add', 'sub', 'mul', 'div', 'sin'],
                           generations=70, init_depth=(4, 10), metric='mse',
                           population_size=500, random_state=0, stopping_criteria=0.01,
                           verbose=1)
```

```

In [48]: # Предсказания
y_gp = est_gp.predict(np.array(xnum_test).reshape(-1, 1))
y_gp[:10]

Out[48]: array([40.28938386, 36.55290694, 44.0910671 , 42.43899561, 47.00219962,
45.03593076, 39.69664985, 46.57498875, 44.92532119, 43.89997191])

In [49]: df['predictions_GPLEARN'] = (train_size * [np.NaN]) + list(y_gp)

In [51]: fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Предсказания временного ряда (тестовая выборка)')
df[train_size:].plot(ax=ax, legend=True)
pyplot.show()

```

Предсказания временного ряда (тестовая выборка)

